UNIVERSIDADE FEDERAL DA PARAÍBA
CENTRO DE INFORMÁTICA
CURSO DE CIÊNCIA DE DADOS E INTELIGÊNCIA ARTIFICIAL

JULIA GABRIELE MENDES BARBOSA
VITÓRIA EMANUELE DE SOUSA SILVA

CLASSIFICAÇÃO DE ESTADOS DE ESTRESSE NA MATRIZ ENERGÉTICA: UM ESTUDO COMPARATIVO COM MACHINE LEARNING

JOÃO PESSOA
2026

SUMÁRIO

1. RESUMO..... 2
2. INTRODUÇÃO.....2
3. OBJETIVO.....3
4. JUSTIFICATIVA.....3
5. METODOLOGIA DE PESQUISA..... 4
5.1 DESCRIÇÃO DO CONJUNTO DE DADOS.....4
5.2 PRÉ-PROCESSAMENTO DOS DADOS..... 5
5.3 ENGENHARIA DE ATRIBUTOS.....5
6. MODELAGEM E RESULTADOS..... 8
6.1 RANDOM FOREST E ÁRVORE DE DECISÃO..... 8
6.2 SUPPORT VECTOR MACHINE (SVM).....10
6.3 REDES NEURAIS ARTIFICIAIS..... 11
7. CONCLUSÃO.....15
REFERÊNCIAS 16

1. RESUMO

A matriz energética brasileira encontra-se em estágio avançado de transição para fontes renováveis variáveis, com destaque para a expansão da geração eólica e solar fotovoltaica no subsistema Nordeste do Sistema Interligado Nacional (SIN). Nesse contexto, o presente trabalho propõe uma classificação binária de estados operativos a partir de variáveis instantâneas de geração renovável e demanda, com base em dados do ONS para o período de 2020 a 2025. Para tanto, foram comparados três algoritmos de Aprendizagem de Máquina: Árvore de Decisão, Random Forest, Support Vector Machine (SVM) e Rede Neural Artificial (RNA). Os resultados demonstraram a superioridade da Rede Neural Artificial, que alcançou acurácia global de 96% e recall de 97% para a classe de estresse, seguida pelo SVM com 93% de acurácia e pela Árvore de Decisão/Random Forest com 92%. Conclui-se que modelos de alta capacidade representacional constituem instrumentos adequados para a detecção automatizada de estados críticos em sistemas elétricos com alta penetração de fontes renováveis variáveis.

2. INTRODUÇÃO

As fontes renováveis já respondem por mais de 90% da capacidade instalada de geração de eletricidade no território nacional, com destaque para o desempenho das usinas fotovoltaicas e dos parques eólicos no Nordeste (ONS apud Portal de Prefeitura, 2026). Embora essa diversificação promova a descarbonização, ela introduz uma volatilidade estocástica que desafia a estabilidade do Sistema Interligado Nacional (SIN). Nesse contexto, a atuação do Operador Nacional do Sistema (ONS) exige a identificação proativa de estados operativos críticos para evitar eventos de desligamento em cascata (apagões) e otimizar o escoamento do excedente energético. Conforme aponta Konzen (2021), com base em estudo da EPE:

> *“No mundo da eletricidade, deve haver um casamento entre oferta e demanda de energia; se o consumo aumenta e os geradores não se adequam rapidamente, ocorrem variações na frequência que podem levar ao acionamento dos dispositivos de proteção, desligando os geradores do sistema. Se não for controlado, o fenômeno pode acontecer em cascata, levando a um apagão” (KONZEN, 2021, online)*

3. OBJETIVO

Conforme aponta Siqueira (2023), o Aprendizado de Máquina tem demonstrado grande potencial no setor elétrico, melhorando a organização da produção, demanda e segurança energética. Nessa perspectiva, o objetivo central deste trabalho consiste em transformar variáveis instantâneas de geração renovável e demanda em indicadores automatizados de segurança operativa para o ONS, com vistas à mitigação de riscos de apagões e sobrecargas decorrentes da elevada volatilidade das fontes renováveis.

Para tanto, propõe-se uma classificação binária de cenários instantâneos, identificando estados como "Normal" (classe 0) ou "Estresse" (classe 1), por meio de uma análise comparativa entre três algoritmos de Aprendizagem de Máquina: Redes Neurais Artificiais (RNA), Support Vector Machine (SVM) e Árvores de Decisão com Random Forest. O modelo resultante atua como ferramenta de diagnóstico que processa dados de geração e carga de um determinado instante e emite um alerta ao ONS quanto ao estado de estresse da rede elétrica.

4. JUSTIFICATIVA

A inconstância natural das fontes renováveis variáveis, afinal, os picos de geração nem sempre coincidem com a curva de demanda, impõe a necessidade de ferramentas analíticas que superem as limitações dos modelos estatísticos tradicionais. Uma vez que esses modelos mostram-se limitados em entender a

complexidade e a não-linearidade dos padrões de estresse presentes em sistemas elétricos.

Nesse contexto, os algoritmos de Aprendizagem de Máquina destacam-se por sua capacidade de generalização, permitindo identificar o rasto de estresse sistêmico a partir de grandes volumes de dados. Essa abordagem viabiliza a predição de estados operativos críticos com base em dados reais disponibilizados pelo ONS para o período de 2020 a 2025, contribuindo para a mitigação de riscos operacionais e para o suporte à tomada de decisão em tempo real.

5. METODOLOGIA DE PESQUISA

5.1 DESCRIÇÃO DO CONJUNTO DE DADOS

Os dados utilizados nesta pesquisa são provenientes do banco de dados público do Operador Nacional do Sistema Elétrico (ONS), abrangendo o período compreendido entre janeiro de 2020 e dezembro de 2025. O conjunto de dados contempla registros em intervalos horários referentes ao subsistema Nordeste e é composto pelas variáveis descritas abaixo.

Quadro 1: Dicionário de variáveis

Campo / Variável	Descrição
id_subsistema	Identificação do subsistema por meio da sigla da(s) região(ões).
nome_subsistema	Nome do subsistema, correspondente à(s) região(ões) que o compõem.
din_instante	Marca temporal do registro, indicando data e hora da medição.
val_gerhidraulica	Total de energia gerada por usinas hidrelétricas no subsistema, expresso em MWmed.
val_gertermica	Energia gerada por fontes térmicas, incluindo combustíveis fósseis e biomassa (MWmed).
val_gereolica	Energia gerada a partir da força dos ventos — geração eólica (MWmed).

val_gersolar	Energia gerada por fontes solares fotovoltaicas (MWmed).
val_carga	Demanda total de energia do subsistema no instante considerado (MWmed).
val_intercambio	Saldo líquido de energia: valores positivos indicam exportação de excedente energético; valores negativos, importação para suprir déficit local (MWmed).

5.2 PRÉ-PROCESSAMENTO DOS DADOS

Os datasets anuais referentes aos anos de 2020 a 2025 foram inicialmente carregados de forma individual, com o objetivo de realizar uma validação preliminar da integridade dos dados. Em seguida, esses conjuntos foram consolidados em uma base única, sendo posteriormente filtrados para contemplar exclusivamente o subsistema Nordeste. Os dados analisados integram o contexto de monitoramento e planejamento do Sistema Interligado Nacional, permitindo a observação da dinâmica entre oferta e demanda de energia elétrica em intervalos horários.

5.3 ENGENHARIA DE ATRIBUTOS

A modelagem de sistemas elétricos a partir de dados operacionais brutos exige o tratamento rigoroso da dimensionalidade temporal. Embora a natureza original da informação seja uma série temporal com granularidade horária, a metodologia adotada optou por remover a dependência sequencial direta do tempo. Essa decisão foi tomada para viabilizar o treinamento e a convergência de modelos estáticos de classificação (como Redes Neurais Artificiais, Árvores de Decisão e SVM) a partir de um resumo estatístico do comportamento diário da rede.

Para efetuar essa transformação, os registros foram agrupados por data, extraindo-se métricas estatísticas específicas de cada variável de oferta e demanda. Esse processamento culminou na consolidação da matriz de atributos X, que passou a ser composta por 23 variáveis preditivas, ou features ($p = 23$). A extração das

métricas foi desenhada para capturar tanto o volume quanto a intermitência do sistema, distribuindo-se da seguinte forma:

- Curtose: indica a presença de outliers no intervalo, sendo especialmente relevante para detecção de picos de geração ou demanda de energia.
- Obliquidade: mensura a assimetria da distribuição dos valores no evento, ou seja, a constância ou variação do comportamento analisado.
- Desvio Padrão, Média, Máximo e Mínimo: caracterizam o espalhamento e amplitude das variações de geração e demanda.

5.3 DEFINIÇÃO DO ALVO (TARGET)

A avaliação de segurança e o diagnóstico de estados críticos em sistemas elétricos podem ser abordados sob diferentes perspectivas metodológicas. No escopo da operação em tempo real, o Operador Nacional do Sistema Elétrico (ONS) avalia o "estresse" do sistema de forma estritamente física e determinística. Para isso, o ONS utiliza ferramentas de análise computacional contínua, como o software Organon, para mapear a chamada Região de Segurança. Sob essa ótica operacional, o sistema atinge um estado crítico (área vermelha) quando rompe limites intrínsecos aos equipamentos e às leis da física, tais como o limite térmico de carregamento das linhas, o limite de estabilidade de tensão (curva do nariz) e o limite de estabilidade eletromecânica. Em contrapartida, de forma a contornar o alto custo computacional das simulações de fluxo de potência continuado necessárias para avaliar esses limites físicos, o presente trabalho propõe uma definição de estresse sob uma perspectiva estatística e macroeconômica, orientada a dados. O estado operativo é definido pela variável val_intercambio. Tecnicamente, valores positivos indicam que o Nordeste exporta seu excedente de geração, enquanto valores negativos apontam para a dependência de importação de outros subsistemas para evitar o colapso (apagão). A lógica matemática para a classificação dos estados de

estresse baseia-se no desvio padrão global (global) do intercâmbio, representando a oscilação típica em dias normais:

- Operação Normal: Definida como o intervalo [média - 1σ, média + 1σ]. Representa a faixa de segurança operativa onde o SIN absorve as variações sem risco estrutural.
- Estados de Estresse: Valores fora desta faixa. O limite superior indica exportação excedente (risco de sobrecarga em linhas de transmissão), enquanto o limite inferior indica necessidade crítica de importação (déficit de geração interna).

5.4 DISTRIBUIÇÃO DOS DADOS

Após a consolidação dos dados brutos do Operador Nacional do Sistema Elétrico (ONS) e a filtragem para o subsistema Nordeste, o dataset original contava com 52.608 registros de granularidade horária. A aplicação da engenharia de atributos, que removeu a dependência sequencial direta do tempo através do agrupamento estatístico por data (din_instante), reduziu a dimensionalidade amostral para N=1753 instâncias diárias, descritas por um espaço de características de p=23 variáveis. A definição da variável alvo (y), induziu uma distribuição específica das classes. Assumindo que o fluxo de energia tende a seguir um comportamento de distribuição normal, estatisticamente espera-se que cerca de 68% (1424) dos dias analisados permaneçam dentro da faixa de operação normal, enquanto os 32%(768) restantes representem as anomalias. Essa proporção natural evidencia um leve desbalanceamento de classes, o que é esperado em problemas de detecção de anomalias operativas. Tal característica exigiu que a avaliação dos modelos não se baseasse apenas na acurácia global, mas também em métricas de precisão e recall, garantindo que os classificadores não adotassem o viés de prever apenas a classe majoritária.

Para validar a capacidade de generalização dos algoritmos desenvolvidos, o banco de dados contendo as 2192 instâncias foi particionado em conjuntos disjuntos

de treinamento e teste. Optou-se empiricamente pela proporção de 80% dos dados para treinamento e 20% para teste. Adicionalmente, o particionamento foi realizado de forma estratificada, garantindo que a proporção original fosse rigorosamente mantida tanto no conjunto de treinamento quanto no conjunto de teste, evitando que o modelo fosse treinado em um cenário não representativo da realidade operativa.

6. MODELAGEM E RESULTADOS

Com uma base de $N = 1753$ amostras diárias, para o conjunto de treino, e $p = 23$ atributos (features), explorou-se um conjunto de modelos para validar a robustez da classificação.

6.1 RANDOM FOREST E ÁRVORE DE DECISÃO

O modelo de Árvore de Decisão atua como uma sequência de regras aplicadas aos dados, dividindo o espaço de atributos a fim de facilitar o processo de classificação. Para o presente modelo, foi necessário aplicar uma regularização por meio da técnica Minimal Cost-Complexity Pruning, realizada via validação cruzada. Essa técnica realiza uma poda da árvore controlada pelo parâmetro *ccp_alpha*, que penaliza a complexidade estrutural do modelo, buscando o equilíbrio entre a pureza dos nós e a capacidade de aprendizado, mitigando o *overfitting*.

Figura 1 - Métrica de erro 1º modelo

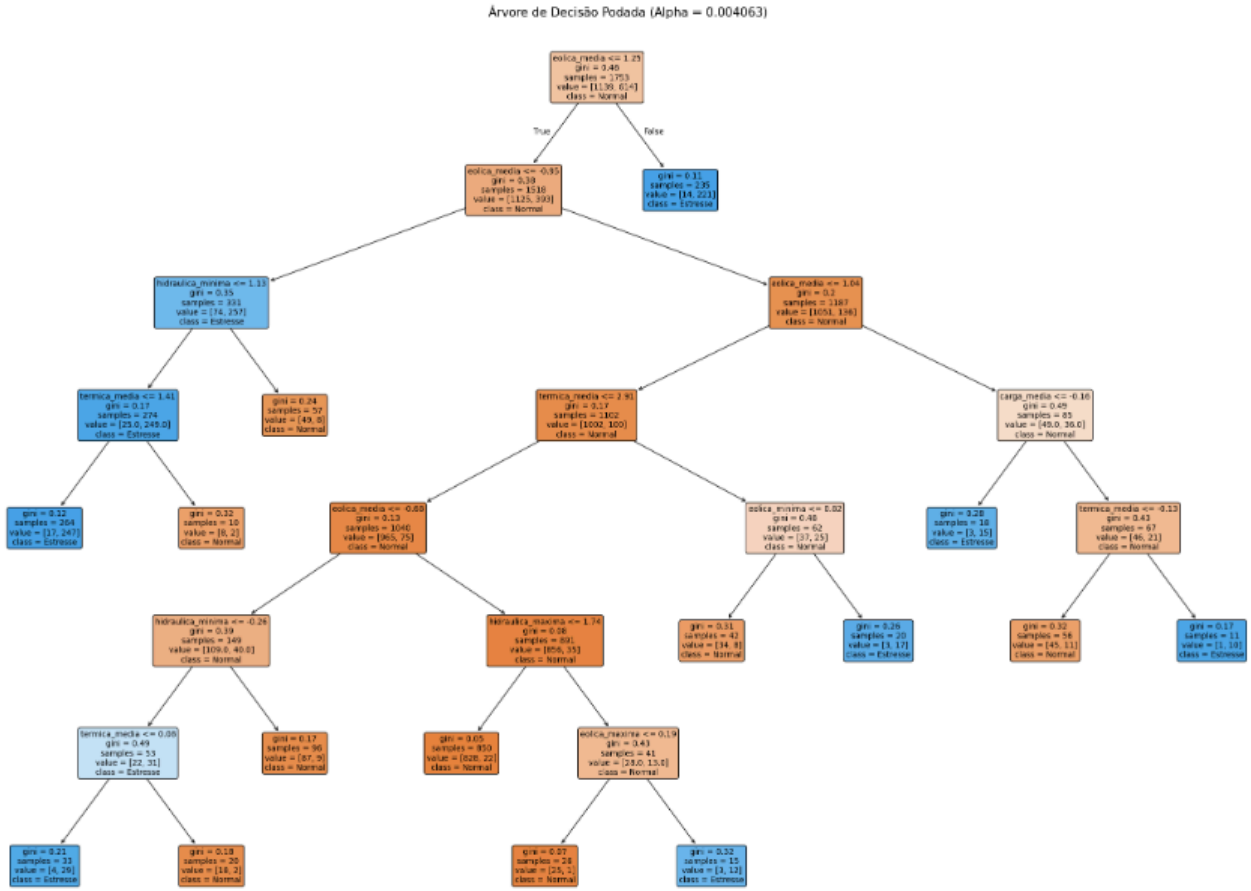

Fonte: autores (2026)

Após feita a regularização as métricas de qualidade foram:

Tabela 1 - Métricas da árvore de decisão

Classe	Precisão	Recall	F1-Score	Suporte
Normal (0)	0,92	0,94	0,93	285
Estresse (1)	0,88	0,86	0,87	154
Acurácia Global	—	—	**0,91**	439
Média Macro	0,90	0,90	0,90	439
Média Ponderada	0,91	0,91	0,91	439

O Random Forest, por sua vez, é um método que combina múltiplas árvores de decisão treinadas de forma paralela e independente, cada uma trabalha sobre uma subamostra aleatória dos dados e dos atributos. A predição final não é determinada pela melhor árvore individualmente, mas sim pela votação da maioria entre todas as árvores do conjunto, o que confere ao modelo maior robustez e capacidade de generalização em comparação a uma árvore isolada.

Tabela 2 - Métricas do random forest

Classe	Precisão	Recall	F1-Score	Suporte
Normal (0)	0,95	0,95	0,95	285
Estresse (1)	0,90	0,90	0,90	154
Acurácia Global	—	—	**0,93**	439
Média Macro	0,92	0,92	0,92	439
Média Ponderada	0,93	0,93	0,93	439

6.2 SUPPORT VECTOR MACHINE (SVM)

O modelo SVM busca separar classes linearmente separáveis, porém nossos dados não são linearmente separáveis. Usamos o kernel RBF para aumentar a dimensão e assim os dados serem separáveis. Para a seleção dos hiperparâmetros ótimos do modelo SVM, foi empregado o método GridSearchCV com validação cruzada estratificada de 5 partições (k=5), garantindo que a estimativa de desempenho fosse robusta e independente de partições favoráveis dos dados.

Os hiperparâmetros selecionados foram:

- **C = 10:** parâmetro de regularização que controla a tolerância a erros de classificação.
- **gamma = scale:** valor calculado automaticamente com base nas características dos dados, controlando o raio de influência de cada vetor de suporte sobre a fronteira de decisão;

- **class_weight = balanced:** configuração utilizada para lidar com o desbalanceamento entre as classes, fazendo com que o modelo penalize proporcionalmente os erros cometidos na classe minoritária, contribuindo para a melhora do recall dessa classe.

Figura 2 - Distribuição e correlação das features

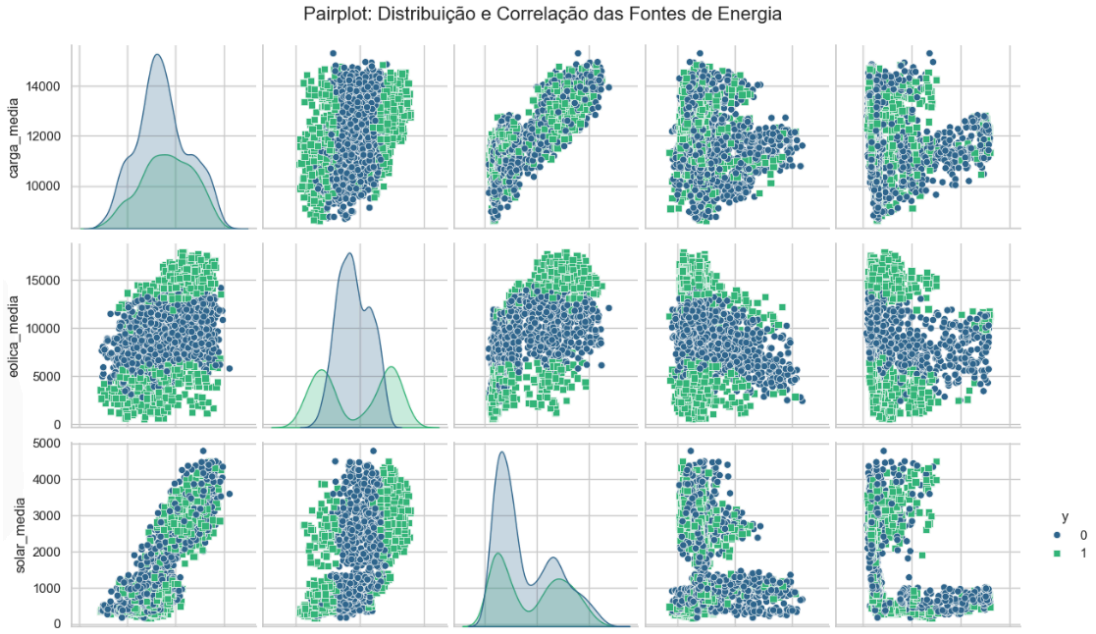

Fonte: autores (2026)

Tabela 3 - Métricas do SVM

Classe / Métrica	Precisão	Recall	F1-Score	Suporte
Normal (0)	0,97	0,92	0,94	285
Estresse (1)	0,86	0,95	0,90	154
Acurácia Global	—	—	**0,93**	439
Média Macro	0,92	0,94	0,92	439
Média Ponderada	0,93	0,93	0,93	439

6.3 REDES NEURAIS ARTIFICIAIS (RNA)

Para o desenvolvimento do modelo de Redes Neurais, adotamos uma abordagem baseada em fundamentos teóricos de generalização e otimização iterativa. Para a definição da estrutura da rede (número de neurônios e camadas ocultas) utilizamos o conceito de Dimensão VC (Vapnik-Chervonenkis) para estimar a capacidade de aprendizado do modelo. Aplicando a "regra de ouro" da Dimensão VC, equilibramos a complexidade da rede com a quantidade de dados disponíveis, garantindo que o modelo tivesse parâmetros suficientes para aprender os padrões de carga e geração sem cair em overfitting.

O modelo inicial da RNA foi construído configurando-se camadas densamente conectadas (dense layers). Para viabilizar o aprendizado de padrões complexos e não-lineares da intermitência energética, como os picos abruptos de carga e as oscilações climáticas capturados pelas 23 variáveis do dataset, as camadas ocultas foram configuradas com a função de ativação ReLU combinada com a inicialização de pesos He Normal (he_normal). Esta escolha estrutural foi adotada para adequar a variância inicial do algoritmo e evitar o problema matemático de "neurônios mortos", permitindo que a rede mapeasse corretamente as anomalias de geração eólica e térmica. Por tratar-se de um problema de classificação binária (operação "Normal" ou "Estresse"), a camada de saída foi projetada com um único neurônio utilizando a função de ativação Sigmóide emparelhada com a inicialização Glorot Normal (Xavier/glorot_normal), que atua prevenindo o desaparecimento do gradiente na região de decisão. Testes empíricos confirmaram a eficácia dessa combinação: enquanto o uso de uma inicialização gaussiana padrão (normal) induzia a rede a um viés de classe majoritária (colapsando a previsão de dias de estresse a um Recall de 0.00), a adoção conjunta do He Normal e Glorot Normal garantiu a propagação correta da informação, elevando imediatamente o Recall da classe minoritária para 14% antes mesmo da aplicação das etapas de regularização.

Definida a arquitetura estrutural da rede, procedeu-se com a configuração do processo de aprendizado. Para otimizar a atualização dos pesos, utilizou-se o

otimizador Adam associado à função de perda binary_crossentropy. Antes do treinamento definitivo, foi conduzido um teste empírico para definir o tamanho do lote (batch size) ideal, avaliando amostras de 8, 16, 32 e 64 instâncias. O tamanho de lote igual a 8 demonstrou o melhor desempenho de generalização, convergindo para o menor Erro de Validação ($E_{out} = 0.0983$). Além disso, implementou-se a técnica de parada antecipada (Early Stopping) com uma paciência de 10 épocas, garantindo que o treinamento fosse interrompido no ponto exato de menor erro, resgatando os melhores pesos para evitar o desgaste computacional e mitigar o overfitting inicial.

A avaliação do modelo inicial revelou um comportamento dicotômico, conforme ilustrado pelo gráfico da curva de aprendizado, Figura 3, e pela Tabela 4 de métricas geradas. Visualmente, a convergência estável entre o erro de treinamento (E_{in}) e validação (E_{out}) atesta o sucesso da restrição topológica imposta pela dimensão VC, comprovando a ausência de overfitting primário (com diferença entre os erros na casa de décimos). Contudo, a análise aprofundada das métricas de qualidade evidencia o viés gerado pelo desbalanceamento da matriz energética. Apesar da acurácia global satisfatória, o recall para a classe de 'Estresse' indicou que o modelo ainda apresenta dificuldades em generalizar as anomalias sub-representadas no dataset.

Figura 3 - Métricas de erro 1º modelo de redes neurais

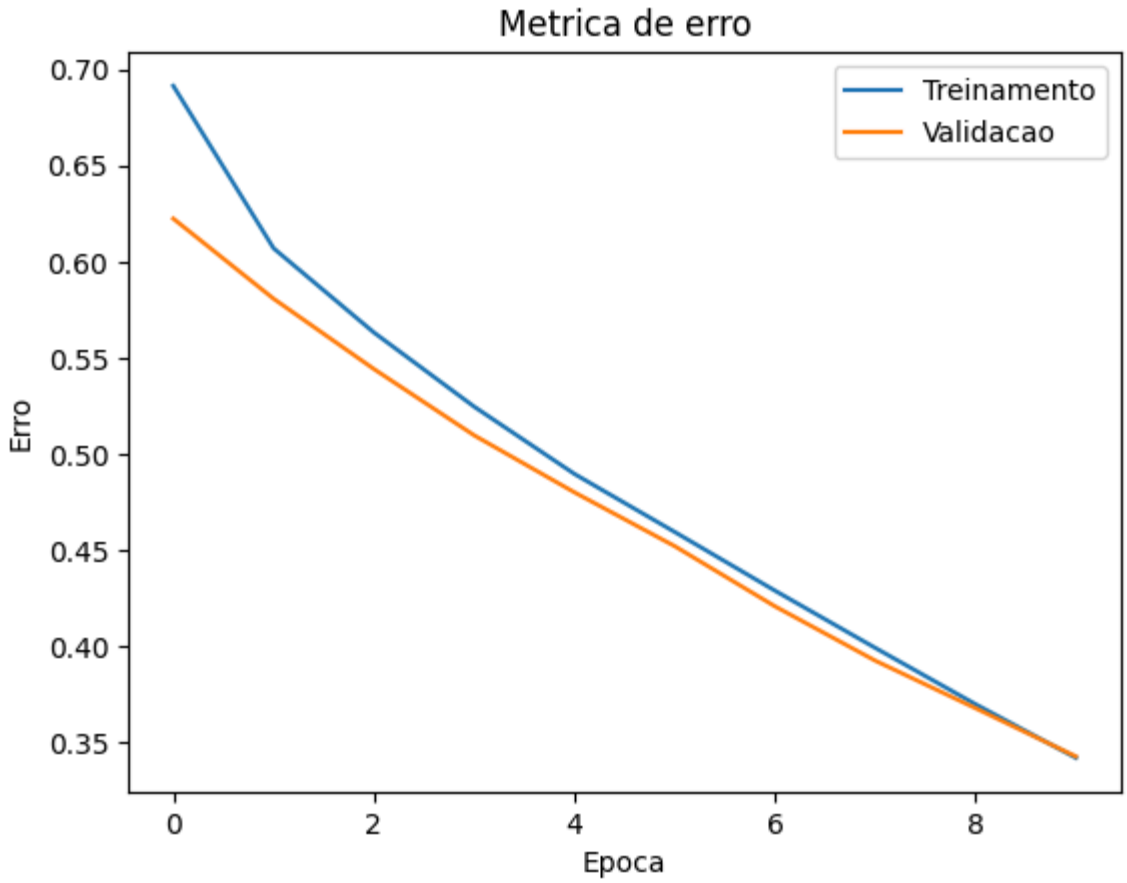

Fonte: autores (2026)

Tabela 4 - Métricas do 1º modelo de redes neurais

Classe / Métrica	Precisão	Recall	F1-Score	Suporte
Normal (0)	0,72	0,79	0,76	285
Estresse (1)	0,54	0,44	0,48	154
Acurácia Global	—	—	**0,67**	439
Média Macro	0,63	0,62	0,62	439
Média Ponderada	0,66	0,67	0,66	439

Este mínimo local de underfitting em relação à classe minoritária justifica estruturalmente a submissão da rede a um grid search para otimização de

hiperparâmetros de regularização (dropout e penalidade L2), visando forçar o algoritmo a extrair os padrões complexos, e validando através da técnica de validação cruzada estratificada (stratified k-fold cross validation). A integração do k-fold (com 5 partições) diretamente no laço de busca garante que cada combinação de parâmetros seja testada de forma cruzada, mantendo a proporção real de dias normais e de estresse em cada dobra. Essa abordagem elimina o viés de uma divisão simples de dados, assegurando que os hiperparâmetros vencedores sejam escolhidos por sua genuína capacidade de generalização e robustez matemática, e não por mero acaso. Os melhores parâmetros obtidos foram o dropout de 0.2 e a penalidade L2 de 0.001 que obteve média de acurácia de 0.9732 nos dados de validação e 0.9799 no treino. Retreinamos a rede com os melhores parâmetros e agora usando todo o conjunto de treino e o conjunto de teste obteve-se uma acurácia de 0.9789 no treino e 0.9567 no teste.

Figura 4 - Métrica de erro modelo otimizado

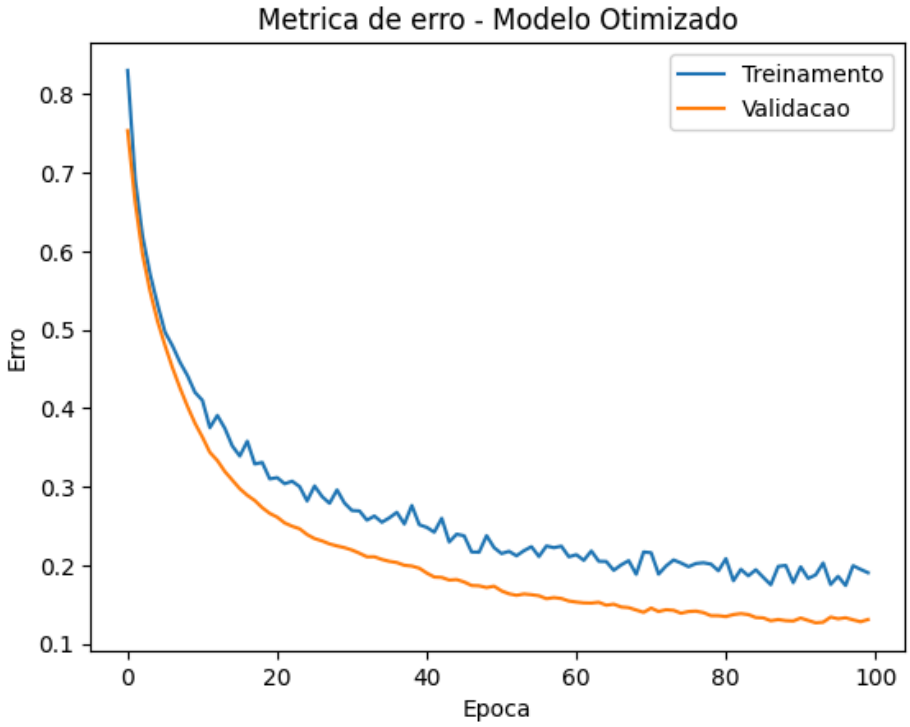

Fonte: autores (2026)

Tabela 5 - Métricas do modelo otimizado

Classe / Métrica	Precisão	Recall	F1-Score	Suporte
Normal (0)	0,97	0,96	0,97	285
Estresse (1)	0,93	0,95	0,94	154
Acurácia Global	—	—	**0,96**	439
Média Macro	0,95	0,95	0,95	439
Média Ponderada	0,96	0,96	0,96	439

7. CONCLUSÃO

Com isso vemos que a rede neural foi nosso modelo com melhores resultados, apresentando acurácia e um recall altos, ou seja, o modelo consegue prever com mais certeza o estresse da rede.

Figura 5: Matriz de confusão comparativa dos modelos

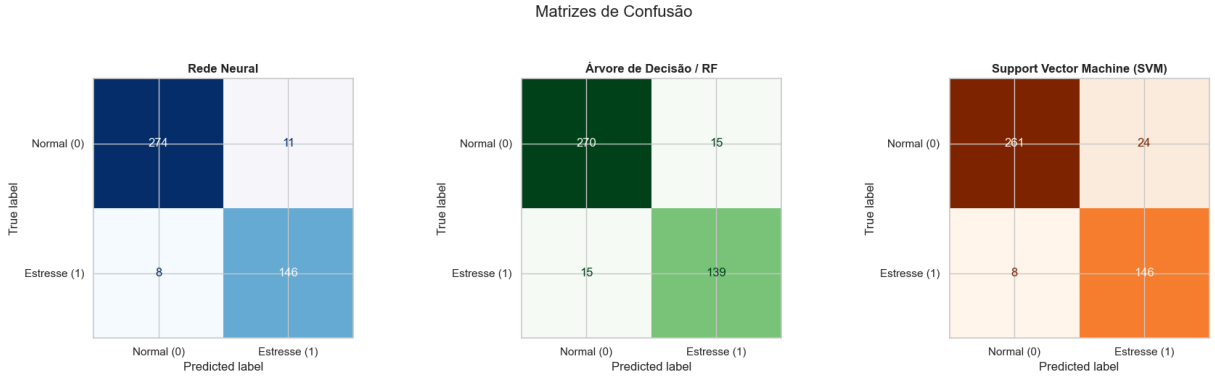

Fonte: autores (2026)

Figura 6: Gráfico de barras cooperativa dos modelos

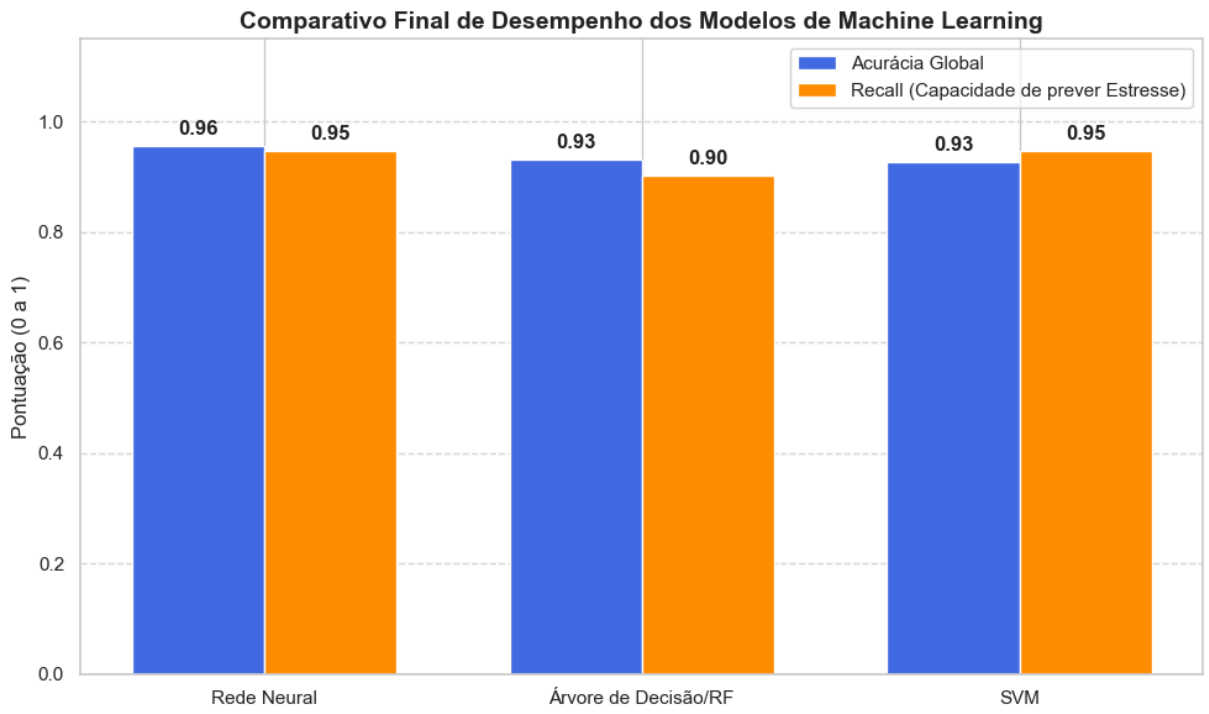

Fonte: autores (2026)

Para mais detalhes de implementações acesse nosso repositorio: https://github.com/Vitoria-Emanuele/AM_ProjetoFinal/blob/main/AM_Aplicacao.ipyn

REFERÊNCIAS

PORTAL DE PREFEITURA. **Saiba como a matriz energética brasileira atinge recorde de fontes renováveis em 2026**. [S.l.], 23 mar. 2026. Disponível em: https://portaldeprefeitura.com.br/bastidores-da-politica/saiba-como-a-matriz-energetica-brasileira-atinge-recorde-de-fontes/617634/. Acesso em: 31 mar. 2026.

KONZEN, Gabriel. **5 maneiras de mitigar os efeitos da geração intermitente**. LinkedIn Pulse, [s.l.], [2021?]. Disponível em: https://pt.linkedin.com/pulse/5-maneiras-de-mitigar-os-efeitos-da-gera%C3%A7%C3%A3o-gabriel-konzen. Acesso em: 31 mar. 2026.

SIQUEIRA, Natássia Rafaelle Medeiros. **Utilização de aprendizado de máquina para classificação de perfis de consumo de energia elétrica nas diferentes regiões do Brasil**. 2023. 104 f. Dissertação (Mestrado em Sistemas e Computação) – Programa de Pós-Graduação em Sistemas e Computação, Departamento de Informática e Matemática Aplicada, Universidade Federal do Rio Grande do Norte, Natal, 2023.